Softmax Regression

3조 한장혁 임동균 하연진

••••

원-핫 인코딩 (One-hot encoding)

- ▶ 선택지의 개수만큼의 차원을 가짐
- ▶ 인덱스에 해당하는 원소가 1, 나머지 0

▶ 원-핫 벡터 무작위성

$$((1,0,0)-(0,1,0))^2=(1-0)^2+(0-1)^2+(0-0)^2=2$$
 $((1,0,0)-(0,0,1))^2=(1-0)^2+(0-0)^2+(0-1)^2=2$

5.2 소프트맥스 회귀 (Softmax Regression)

- 소프트맥스 회귀는 다중 분류를 하기 위한 기본적은 회귀


- 총 확률의 합이 1

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}} \ \ for \ i = 1, 2, \dots k$$

- Softmax 함수

- 소프트맥스 회귀 구크

5.2 소프트맥스 회귀 (Softmax Regression)



크로스 엔트로피 함수

$$cost(W) = -\sum_{j=1}^k y_j \ log(p_j)$$

평균

$$cost(W) = -rac{1}{n} \sum_{i=1}^{n} \sum_{j=1}^{k} y_{j}^{(i)} \; log(p_{j}^{(i)})$$

5.3 소프트맥스 회귀의 비용 함수 구현하기 (Low-Level)

```
import torch
import torch.nn.functional as F
```

torch.manual_seed(1)

(1) torch.rand

z = torch.rand(3, 5, requires grad=True)

TORCH.RAND

torch.rand(*size, *, out=None, dtype=None, layout=torch.strided, device=None, requires_grad=False) → Tensor

Returns a tensor filled with random numbers from a uniform distribution on the interval $\left[0,1\right)$

The shape of the tensor is defined by the variable argument size.

Parameters

size (int...) - a sequence of integers defining the shape of the output tensor. Can be a variable number of arguments or a collection like a list or tuple.

Keyword Arguments

- generator (torch.Generator, optional) a pseudorandom number generator for sampling
- out (Tensor, optional) the output tensor.
- dtype (torch.dtype, optional) the desired data type of returned tensor. Default: if None, uses a global default (see torch.set_default_tensor_type()).
- layout (torch.layout, optional) the desired layout of returned Tensor. Default: torch.strided.
- . device (torch.device, optional) the desired device of returned tensor. Default: if None, uses the current device for the default tensor type (see torch.set_default_tensor_type()). device will be the CPU for CPU tensor types and the current CUDA device for CUDA tensor types.
- requires_grad (bool, optional) If autograd should record operations on the returned tensor. Default: False.

5.3 소프트맥스 회귀의 비용 함수 구현하기 (Low-Level)

(2) torch.nn.functional.softmax

```
hypothesis = F.softmax(z, dim=1)
print(hypothesis)
tensor([[0.2645, 0.1639, 0.1855, 0.2585, 0.1277],
        [0.2430, 0.1624, 0.2322, 0.1930, 0.1694],
        [0.2226, 0.1986, 0.2326, 0.1594, 0.1868]], grad fn=<SoftmaxBackward>)
```

TORCH.NN.FUNCTIONAL.SOFTMAX

torch.nn.functional.softmax(input, dim=None, _stacklevel=3, dtype=None) [SOURCE]

Applies a softmax function.

Softmax is defined as:

$$ext{Softmax}(x_i) = rac{\exp(x_i)}{\sum_i \exp(x_j)}$$

It is applied to all slices along dim, and will re-scale them so that the elements lie in the range [0, 1] and sum to 1.

See Softmax for more details.

Parameters

- input (Tensor) input
- dim (int) A dimension along which softmax will be computed.
- dtype (torch.dtype, optional) the desired data type of returned tensor. If specified, the input tensor is casted to dtype before the operation is performed. This is useful for preventing data type overflows. Default: None.

소프트맥스 회귀의 비용 함수 구현하기 (Low-Level)

(3) torch.randint

```
y = torch.randint(5, (3,)).long()
print(y)

tensor([0, 2, 1])
```

TORCH.RANDINT

torch.randint(low=0, high, size, *, generator=None, out=None, dtype=None, layout=torch.strided, device=None, requires_grad=False) \rightarrow Tensor

Returns a tensor filled with random integers generated uniformly between low (inclusive) and high (exclusive).

The shape of the tensor is defined by the variable argument size.

5.3 소프트맥스 회귀의 비용 함수 구현하기 (Low-Level)

(4) One-HotEncoding (torch.tensor.scatter_)

```
# 모든 원소가 0의 값을 가진 3 x 5 텐서 생성
y one hot = torch.zeros like(hypothesis)
y_one_hot.scatter_(1, y.unsqueeze(1), 1)
tensor([[1., 0., 0., 0., 0.],
      [0., 0., 1., 0., 0.],
      [0., 1., 0., 0., 0.]])
```

TORCH.TENSOR.SCATTER

Tensor.scatter_(dim, index, src, reduce=None) → Tensor

Writes all values from the tensor src into self at the indices specified in the index tensor. For each value in src, its output index is specified by its index in src for dimension != dim and by the corresponding value in index for dimension = dim.

For a 3-D tensor, self is updated as:

```
self[index[i][j][k]][j][k] = src[i][j][k] # if dim == 0
self[i][index[i][j][k]][k] = src[i][j][k] # if dim == 1
self[i][j][index[i][j][k]] = src[i][j][k] # if dim == 2
```

This is the reverse operation of the manner described in gather().

self, index and src (if it is a Tensor) should all have the same number of dimensions. It is also required that index.size(d) <= src.size(d) for all dimensions d, and that index.size(d) <= self.size(d) for all dimensions d != dim . Note that index and src do not broadcast.

Moreover, as for gather(), the values of index must be between 0 and self.size(dim) - 1 inclusive.

(unsqueeze는 특정 위치에 1인 차원을 추가하는 것)

Parameters

- dim (int) the axis along which to index
- index (LongTensor) the indices of elements to scatter, can be either empty or of the same dimensionality as src . When empty, the operation returns self unchanged.
- src (Tensor or float) the source element(s) to scatter.
- reduce (str, optional) reduction operation to apply, can be either 'add' or 'multiply'.

5.3 소프트맥스 회귀의 비용 함수 구현하기 (Low-Level)

(5) cost function

$$cost(W) = -\frac{1}{n} \sum_{i=1}^{n} \sum_{j=1}^{k} y_{j}^{(i)} log(p_{j}^{(i)})$$

$$cost(W) = \frac{1}{n} \sum_{i=1}^{n} \sum_{j=1}^{k} y_{j}^{(i)} \times (-log(p_{j}^{(i)}))$$

```
cost = (y_one_hot * -torch.log(hypothesis)).sum(dim=1).mean()
print(cost)
```

tensor(1.4689, grad_fn=<MeanBackward1>)

5.3 소프트맥스 회귀의 비용 함수 구현하기 (High-Level)

1. F.softmax() + torch.log() = F.log_softmax()

```
# Low level
torch.log(F.softmax(z, dim=1))
tensor([[-1.3301, -1.8084, -1.6846, -1.3530, -2.0584],
        [-1.4147, -1.8174, -1.4602, -1.6450, -1.7758],
        [-1.5025, -1.6165, -1.4586, -1.8360, -1.6776]], grad fn=<LogBackward>)
# High level
F.log_softmax(z, dim=1)
tensor([[-1.3301, -1.8084, -1.6846, -1.3530, -2.0584],
        [-1.4147, -1.8174, -1.4602, -1.6450, -1.7758],
        [-1.5025, -1.6165, -1.4586, -1.8360, -1.6776]], grad_fn=<LogSoftmaxBackward>)
```

5.3 소프트맥스 회귀의 비용 함수 구현하기 (High-Level)

2. F.log_softmax() + F.nll_loss() = F.cross_entropy()

<Low level>

```
# 두번째 수식
(y one hot * - F.log softmax(z, dim=1)).sum(dim=1).mean()
tensor(1.4689, grad fn=<MeanBackward0>)
```

*F.nll_loss()를 사용할 때는 원-핫 벡터를 넣을 필요없이 바로 실제값을 인자로 사용합니다.

```
# 네번째 수식
F.cross_entropy(z, y)
tensor(1.4689, grad_fn=<NllLossBackward>)
```

<High level>

```
# High level
# 세번째 수식
F.nll_loss(F.log_softmax(z, dim=1), y)
tensor(1.4689, grad_fn=<NllLossBackward>)
```

5.4 소프트맥스 회귀 구현하기 (Low-Level)

2. F.log_softmax() + F.nll_loss() = F.cross_entropy()

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
torch.manual seed(1)
```

#데이터 선언

```
x_{train} = [[1, 2, 1, 1],
          [2, 1, 3, 2],
          [3, 1, 3, 4],
          [4, 1, 5, 5],
          [1, 7, 5, 5],
          [1, 2, 5, 6],
          [1, 6, 6, 6],
          [1, 7, 7, 7]]
y_train = [2, 2, 2, 1, 1, 1, 0, 0]
x_train = torch.FloatTensor(x_train)
y train = torch.LongTensor(y train)
```

#모델 초기화 & optimizer 설정

```
# 모델 초기화
W = torch.zeros((4, 3), requires_grad=True)
b = torch.zeros(1, requires_grad=True)
# optimizer 설정
optimizer = optim.SGD([W, b], lr=0.1)
```

#가설 설정 & 비용 함수 선언 및 개선

```
nb_epochs = 1000
for epoch in range(nb epochs + 1):
   # 가설
   hypothesis = F.softmax(x train.matmul(W) + b, dim=1)
   # 비용 함수
   cost = (y_one_hot * -torch.log(hypothesis)).sum(dim=1).mean()
   # cost로 H(x) 개선
   optimizer.zero grad()
   cost.backward()
   optimizer.step()
   # 100번마다 로그 출력
   if epoch % 100 == 0:
       print('Epoch {:4d}/{} Cost: {:.6f}'.format(
           epoch, nb epochs, cost.item()
       ))
```

5.4 소프트맥스 회귀 구현하기 (High-Level)

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
torch.manual seed(1)
```

#데이터 선언

```
x_{train} = [[1, 2, 1, 1],
          [2, 1, 3, 2],
          [3, 1, 3, 4],
          [4, 1, 5, 5],
          [1, 7, 5, 5],
          [1, 2, 5, 6],
          [1, 6, 6, 6],
          [1, 7, 7, 7]]
y_train = [2, 2, 2, 1, 1, 1, 0, 0]
x_train = torch.FloatTensor(x_train)
y train = torch.LongTensor(y train)
```

#모델 초기화 & optimizer 설정

```
# 모델 초기화
W = torch.zeros((4, 3), requires grad=True)
b = torch.zeros(1, requires grad=True)
# optimizer 설정
optimizer = optim.SGD([W, b], lr=0.1)
```

••••

#가설 설정 & 비용 함수 선언 및 개선

```
nb epochs = 1000
for epoch in range(nb epochs + 1):
    # Cost 계산
   z = x_{train.matmul(W)} + b
    cost = F.cross entropy(z, y train)
   # cost로 H(x) 개선
    optimizer.zero_grad()
    cost.backward()
    optimizer.step()
    # 100번마다 로그 출력
    if epoch % 100 == 0:
       print('Epoch {:4d}/{} Cost: {:.6f}'.format(
           epoch, nb_epochs, cost.item()
       ))
```

5.4 소프트맥스 회귀 nn.Module로 구현하기

```
model = nn.Linear(4, 3)
# optimizer 설정
optimizer = optim.SGD(model.parameters(), lr=0.1)
nb epochs = 1000
for epoch in range(nb epochs + 1):
```

- ❖ nn.Linear 사용
- ❖ Output dim = 클래스의 개수
- ❖ F.cross entropy는 그 자체로 소프트 맥스 함수를 포함하므로 가설을 정의하지 않는다.
- ❖ 옵티마이저 = 경사하강법 SGD / 학습률 = 0.1
- ❖ Zero grad = gradient를 0으로 만들기 위함

```
# H(x) 계산
prediction = model(x train)
# cost 계산
cost = F.cross entropy(prediction, y train)
# cost로 H(x) 개선
optimizer.zero grad()
cost.backward()
optimizer.step()
# 20번마다 로그 출력
if epoch % 100 == 0:
   print('Epoch {:4d}/{} Cost: {:.6f}'.format(
       epoch, nb epochs, cost.item()
```

```
class SoftmaxClassifierModel(nn.Module):
    def __init__(self):
        super().__init__()
        self.linear = nn.Linear(4, 3) # Output() 3!
    def forward(self, x):
        return self.linear(x)
. . .
model = SoftmaxClassifierModel()
```


```
# optimizer 설정
optimizer = optim.SGD(model.parameters(), lr=0.1)
nb epochs = 1000
for epoch in range(nb epochs + 1):
   # H(x) 계산
    prediction = model(x_train)
   # cost 계산
   cost = F.cross_entropy(prediction, y_train)
   # cost로 H(x) 개선
   optimizer.zero_grad()
   cost.backward()
   optimizer.step()
    # 20번마다 로그 출력
   if epoch % 100 == 0:
       print('Epoch {:4d}/{} Cost: {:.6f}'.format(
           epoch, nb epochs, cost.item()
       ))
```

5.4 소프트맥스 회귀 클래스로 구현하기

Epoch / Batch Size / Iteration

- 에포크 = 트레이닝 셋이 전체 한 번 학습에 사용이 되면 한 에포크가 돌았다.
- ex) 6만장이 다 트레이닝에 사용되면 한 에포크가 돌았다.
- ▶ 배치사이즈 = 한 번 트레이닝에 사용할 때 6만장을 어떤 크기의 묶음으로 나눌 것인가.
- ex) 한 배치의 크기 = 100 / 6만장을 통해 총 600개의 배치를 얻을 수 있다.
- ▶ 이터레이션 = 배치를 몇 번 학습에 사용을 했는가
- ex) 1000개의 트레이닝 셋을 배치사이즈 500이면 2개의 배치가 있다는 것이고 2번의 이터레이션을 완료 하면 1 에포크가 끝난다.

• MNIST 데이터란? 0~9까지의 숫자가 손글씨 이미지로 표현된 데이터셋



24 X 24 = 784차원의 벡터 생성

```
for X, Y in data_loader:
 # 입력 이미지를 [batch_size x 784]의 크기로 reshape
 # 레이블은 원-핫 인코딩
 X = X.view(-1, 28*28)
```

분류기 구현을 위한 사전 설정

```
import torch
import torchvision.datasets as dsets
import torchvision.transforms as transforms
from torch.utils.data import DataLoader
import torch.nn as nn
import matplotlib.pyplot as plt
import random
USE_CUDA = torch.cuda.is_available() # GPU를 사용가능하면 True, 아니라면 False를 리턴
device = torch.device("cuda" if USE CUDA else "cpu")
# GPU 사용 가능하면 사용하고 아니면 CPU 사용
print("다음 기기로 학습합니다:", device)
```

▶ 랜덤 시드 고정

```
# for reproducibility
random.seed(777)
torch.manual seed(777)
if device == 'cuda':
   torch.cuda.manual seed all(777)
```

▶ 하이퍼파라미터를 변수로 둔다.

```
# hyperparameters
training epochs = 15
batch size = 100
```

MNIST 분류기 구현하기


- ▶ 데이터 불러오기 torchvision.datasets.dsets.MNIST

```
▶ 데이터 다운로드
```

```
# MNIST dataset
mnist_train = dsets.MNIST(root='MNIST_data/',
                          train=True,
                          transform=transforms.ToTensor(),
                          download=True)
mnist_test = dsets.MNIST(root='MNIST_data/',
                         train=False,
                         transform=transforms.ToTensor(),
                         download=True)
```

▶ 데이터로더 사용

```
# dataset loader
data loader = DataLoader(dataset=mnist train,
                                         batch size=batch size, # 배치 크기는 100
                                         shuffle=True,
                                         drop last=True)
```



```
# MNIST 분류기 구현하기
```

- ▶ 모델 설계
 - \rightarrow Input_dim = 784
 - > Output_dim = 10

```
# MNIST data image of shape 28 * 28 = 784
linear = nn.Linear(784, 10, bias=True).to(device)
```

▶ 비용 함수, 옵티마이저 정의

함하는 크로스 엔트로

```
for epochin range(training epochs): # 앞서 training epochs의 값은 15로 지정함.
   avg cost = 0
   total batch = len(data loader)
for X, Yin data loader:
       # 배치 크기가 100이므로 아래의 연산에서 X는 (100, 784)의 텐서가 된다.
       X = X.view(-1, 28 * 28).to(device)
       # 레이블은 원-핫 인코딩이 된 상태가 아니라 0~9의 정수.
       Y = Y.to(device)
       optimizer.zero grad()
       hypothesis = linear(X)
       cost = criterion(hypothesis, Y)
       cost.backward()
       optimizer.step()
       avg_cost += cost / total_batch
   print('Epoch:', '%04d' % (epoch + 1), 'cost =', '{:.9f}'.format(avg_cost))
print('Learning finished')
```

```
criterion = nn.CrossEntropyLoss().to(device) # 내부적으로 소프트맥스 함수를 포함하
고 있음.
optimizer = torch.optim.SGD(linear.parameters(), lr=0.1)
```

Epoch: 0001 cost = 0.535468459 Epoch: 0002 cost = 0.359274209Epoch: 0003 cost = 0.331187516 Epoch: 0004 cost = 0.316578060 Epoch: 0005 cost = 0.307158142 Epoch: 0006 cost = 0.300180763 Epoch: 0007 cost = 0.295130193 Epoch: 0008 cost = 0.290851474 Epoch: 0009 cost = 0.287417054 Epoch: 0010 cost = 0.284379572 Epoch: 0011 cost = 0.281825274 Epoch: 0012 cost = 0.279800713 Epoch: 0013 cost = 0.277808994 Epoch: 0014 cost = 0.276154339 Epoch: 0015 cost = 0.274440885 Learning finished

MNIST 분류기 구현하기_TEST

Test

```
# Test the model using test sets
With torch.no grad():
   X_test = mnist_test.test_data.view(-1, 28 * 28).float().to(device)
   Y test = mnist test.test labels.to(device)
    prediction = linear(X_test)
    correct_prediction = torch.argmax(prediction, 1) == Y_test
    accuracy = correct_prediction.float().mean()
    print("Accuracy: ", accuracy.item())
```

Thank you!